# 字母表 (Alphabet)

- ▶字母表∑是一个有穷符号集合
  - ▶符号:字母、数字、标点符号、...

### 例:

- ▶二进制字母表: {0,1}
- >ASCII字符集
- >Unicode字符集

 $\triangleright$ 字母表 $\sum_{1}$ 和 $\sum_{2}$ 的乘积(product)

$$\triangleright \sum_{1} \sum_{2} = \{ab | a \in \sum_{1}, b \in \sum_{2}\}$$

例:  $\{0,1\}$   $\{a,b\}$  =  $\{0a,0b,1a,1b\}$ 

- $\triangleright$ 字母表 $\sum_{1}$ 和 $\sum_{2}$ 的乘积(product)
- >字母表∑的n次幂(power)

$$\begin{cases} \sum^{0} = \{ \varepsilon \} \\ \sum^{n} = \sum^{n-1} \sum_{i} n \geq 1 \end{cases}$$

例: 
$$\{0,1\}^3 = \{0,1\} \{0,1\} \{0,1\}$$
  
= $\{000,001,010,011,100,101,110,111\}$ 

字母表的n次幂:长度为n的符号串构成的集合

- $\triangleright$ 字母表 $\sum_{1}$ 和 $\sum_{2}$ 的乘积(product)
- >字母表∑的n次幂(power)
- ▶字母表∑的正闭包(positive closure)

$$\triangleright \Sigma^+ = \Sigma \cup \Sigma^2 \cup \Sigma^3 \cup \dots$$

例:  $\{a, b, c, d\}^+ = \{a, b, c, d, aa, ab, ac, ad, ba, bb, bc, bd, ..., aaa, aab, aac, aad, aba, abb, abc, ...\}$ 

字母表的正闭包:长度正数的符号串构成的集合

- $\triangleright$ 字母表 $\sum_{1}$ 和 $\sum_{2}$ 的乘积(product)
- >字母表∑的n次幂(power)
- ▶字母表∑的正闭包(positive closure)
- >字母表∑的克林闭包(Kleene closure)
  - $\triangleright \Sigma^* = \Sigma^0 \cup \Sigma^+ = \Sigma^0 \cup \Sigma \cup \Sigma^2 \cup \Sigma^3 \cup \dots$

ঙ্গি:  $\{a, b, c, d\}^* = \{\varepsilon, a, b, c, d, aa, ab, ac, ad, ba, bb, bc, bd, ..., aaa, aab, aac, aad, aba, abb, abc, ...\}$ 

字母表的克林闭包:任意符号串(长度可以为零)构成的集合

# 串(String)

- Arr>设Arr2是一个字母表,Arr4Arr5Arr7Arr7Arr8Arr9。 → 串是字母表中符号的一个有穷序列
- ▶ 串 s 的 长度, 通常记作 | s | , 是指 s 中 符号的 个数▶ 例: |aab|=3
- ightharpoonup 空串是长度为0的串,用 $\varepsilon$  (epsilon) 表示  $ightharpoonup |\varepsilon| = 0$

# 串上的运算——连接

- 一如果x和y是串,那么x和y的连接(concatenation)是把y附加到x后面而形成的串,记作xy
  - ▶ 例如,如果 x=dog且 y=house, 那 么xy=doghouse
  - 文字是连接运算的单位元(identity),即,对于任何串S都有, $\mathcal{E}S = S\mathcal{E} = S$

设x,y,z是三个字符串,如果x=yz,则称y是x的前缀,z是x的后缀

# 串上的运算——幂

▶串s的幂运算

$$\begin{cases} s^0 = \varepsilon, \\ s^n = s^{n-1}s, n \ge 1 \end{cases}$$

- $>s^1=s^0s=\varepsilon s=s$ ,  $s^2=ss$ ,  $s^3=sss$ , ...
- $\triangleright$ 例:如果s=ba,那么 $s^1=ba$ , $s^2=baba$ , $s^3=bababa$ ,…

串s的n次幂:将n个s连接起来

# 自然语言的例子——句子的构成规则

- →<句子>→<名词短语><动词短语>
- →<名词短语>→<形容词><名词短语>
- ▶<名词短语>→<名词>
- ▶<动词短语>→<动词><名词短语>
- ▶<形容词> → little
- **><名词>→boy**
- ><名词>→ apple
- $\rightarrow$  < 动词>  $\rightarrow$  eat

未用尖括号括起来部分表示语言的基本符号

尖括号括起来部分称为语法成分

$$G = (V_T, V_N, P, S)$$

 $\triangleright V_T$ : 终结符集合

终结符 (terminal symbol) 是文法所定义的语言的基本符号,有时也称为token

 $\triangleright$ 例:  $V_T = \{ apple, boy, eat, little \}$ 

$$G = (V_T, V_N, P, S)$$

- $\triangleright V_T$ : 终结符集合
- $\triangleright V_N$ : 非终结符集合
  - 非终结符(nonterminal) 是用来表示语法成分的符号, 有时也称为"语法变量"

$$G = (V_T, V_N, P, S)$$

 $\triangleright V_T$ : 终结符集合

$$V_T \cap V_N = \Phi$$

 $\triangleright V_N$ : 非终结符集合

 $\triangleright P$ : 产生式集合

 $V_T \cup V_N$ : 文法符号集

产生式(production)描述了将终结符和非终结符组合成串的方法 产生式的一般形式:

$$\alpha \rightarrow \beta$$

读作:  $\alpha$ 定义为 $\beta$ 

- $> \beta \in (V_T \cup V_N)^* : 称为产生式的体(body)或右部(right side)$

$$G = (V_T, V_N, P, S)$$

- $\triangleright V_T$ : 终结符集合
- $\triangleright V_N$ : 非终结符集合
- P: 产生式集合

产生式(production)描述了将终结符和非终结符组合成串的方法产生式的一般形式:

$$\alpha \rightarrow \beta$$
 $P = \langle 67 \rangle \rightarrow \langle 27 \rangle \rightarrow \langle 37 \rangle$ 

$$G = (V_T, V_N, P, S)$$

- $\triangleright V_T$ : 终结符集合
- $\triangleright V_N$ : 非终结符集合
- PP: 产生式集合
- ▶S: 开始符号

 $S \in V_N$ 。开始符号(start symbol) 表示的是该文法中最大的语法成分

►例: S = < 句子>

$$G = (V_T, V_N, P, S)$$

- $\triangleright V_T$ : 终结符集合
- $\triangleright V_N$ : 非终结符集合
- P: 产生式集合
- ▶S: 开始符号

expression 约定:

例:  $G = (\{ id, +, *, (, ) \}, \{E\}, P, E )$   $P = \{ E \rightarrow E + E,$   $E \rightarrow E * E,$   $E \rightarrow (E),$  $E \rightarrow id \}$ 

不引起歧义的 前提下,可以 只写产生式

 $G: E \rightarrow E + E$   $E \rightarrow E * E$   $E \rightarrow (E)$   $E \rightarrow id$ 

# 产生式的简写

>对一组有相同左部的α产生式

$$\alpha \rightarrow \beta_1, \alpha \rightarrow \beta_2, \dots, \alpha \rightarrow \beta_n$$

可以简记为:

$$\alpha \rightarrow \beta_1 \mid \beta_2 \mid \dots \mid \beta_n$$

读作:  $\alpha$ 定义为 $\beta_1$ , 或者 $\beta_2$ , ..., 或者 $\beta_n$  。

$$\beta_1, \beta_2, ..., \beta_n$$
称为 $\alpha$ 的候选式(Candidate)

$$egin{aligned} egin{aligned} E 
ightharpoonup E + E \ E 
ightharpoonup E 
ightharpoonup E 
ightharpoonup E \ E 
ightharpoonup id \end{aligned}$$



# 符号约定

- 户下述符号是终结符
  - $\triangleright(a)$  字母表中排在前面的小写字母,如 $a \lor b \lor c$
  - **▶**(b) 运算符,如 +、\*等
  - ▶(c) 标点符号, 如括号、逗号等
  - **▶**(*d*) 数字0、1、...、9
  - $\triangleright(e)$  粗体字符串,如id、if等

# 符号约定

- 户下述符号是终结符
- 户下述符号是非终结符
  - $\triangleright(a)$  字母表中排在前面的大写字母,如 $A \lor B \lor C$
  - ▶(b) 字母S。通常表示开始符号
  - $\triangleright(c)$  小写、斜体的名字,如 expr、stmt等
  - $\triangleright$ (d) 代表程序构造的大写字母。如E(表达式)、T(项)和F(因子)

# 符号约定

- >下述符号是终结符
- ▶下述符号是非终结符 文法符号 X,Y,Z
- 终结符 a,b,c非终结符 A, B, C

终结符号串 u, v, ..., z

文法符号串  $\alpha, \beta, \gamma$ 

- ▶字母表中排在后面的大写字母(如X、Y、Z) 表示文法符号 (即终结符或非终结符)
- ▶字母表中排在后面的小写字母(主要是u、v、...、z) 表示终结符号串 (包括空串)
- $\triangleright$  小写希腊字母,如 $\alpha$ 、 $\beta$ 、 $\gamma$ ,表示文法符号串(包括空串)
- >除非特别说明,第一个产生式的左部就是开始符号

# 自然语言的例子

### 文法:

- ①<句子>→<名词短语><动词短语>
- ② <名词短语> → <形容词> <名词短语>
- ③<名词短语>→<名词>
- ④<动词短语>→<动词><名词短语>
- (5) <形 容词> → little
- ⑥ <名词> → boy
- ⑦ <名词>  $\rightarrow$  apple
- **⑧**<动词>→ eat

单词串: little boy eats apple

有了文法(语言规则),如何判定一个词串是否是满足文法的句子?

# 推导 (Derivations) 和归约(Reductions)

- 》给定文法 $G=(V_T,V_N,P,S)$ ,如果  $\alpha \to \beta \in P$ ,那么可以将符号串 $\gamma \alpha \delta$ 中的 $\alpha$ 替换为 $\beta$ ,也就是说,将 $\gamma \alpha \delta$ 重写(rewrite)为 $\gamma \beta \delta$ ,记作  $\gamma \alpha \delta \to \gamma \beta \delta$ 。此时,称文法中的符号串  $\gamma \alpha \delta$  直接推导(directly derive)出  $\gamma \beta \delta$ 
  - >简而言之, 就是用产生式的右部替换产生式的左部

# 推导 (Derivations)和归约(Reductions)


- 》如果 $\alpha_0 \Rightarrow \alpha_1, \ \alpha_1 \Rightarrow \alpha_2, \ \alpha_2 \Rightarrow \alpha_3, \ \dots, \ \alpha_{n-1} \Rightarrow \alpha_n, \ 则$ 可以记作 $\alpha_0 \Rightarrow \alpha_1 \Rightarrow \alpha_2 \Rightarrow \alpha_3 \Rightarrow \dots \Rightarrow \alpha_{n-1} \Rightarrow \alpha_n, \ 称符号串 \alpha_0 经过n步推导出<math>\alpha_n, \ \text{可简记为}\alpha_0 \Rightarrow^n \alpha_n$ 
  - $> \alpha \Longrightarrow^0 \alpha$
  - ▶→\*表示"经过正数步推导"
  - ▶→\*表示"经过若干(可以是0)步推导"

# 推导 (Derivations) 和归约(Reductions)

### 例

#### 文法:

- ① <句子>→<名词短语><动词短语>
- ② <名词短语>→<形容词><名词短语>
- ③ <名词短语>→<名词>
- ④ <动词短语>→<动词><名词短语>
- ⑤ <形 容词> → *little*
- ⑥ <名词>→boy
- ⑦ <名词>→apple
- **⑧** <动词> → eat



# 回答前面的问题

- 一有了文法(语言规则),如何判定某一词串是否 是该语言的句子?
  - ▶句子的推导(派生)-从生成语言的角度▶句子的归约→从识别语言的角度→均根据规则

# 句型和句子

- ▶如果 $S \Rightarrow^* \alpha$ ,  $\alpha \in (V_T \cup V_N)^*$ , 则称α是G的一个句型 (sentential form)
  - ▶一个句型中既可以包含终结符,又可以包含非终结符,也可能是空串
- $\triangleright$ 如果 $S \Rightarrow^* w, w \in V_T^*$ ,则称w是G的一个句子(sentence)
  - 户句子是不包含非终结符的句型

# 例

- <句子>⇒<名词短语><动词短语>
  - ⇒<形容词><名词短语><动词短语>
  - ⇒ little <名词短语> <动词短语>
  - ⇒ little <名词> <动词短语>
  - ⇒ little boy <动词短语>
  - ⇒ little boy <动词><名词短语>
  - ⇒ little boy eats <名词短语>
  - ⇒ little boy eats <名词>
- 句子 → ⇒ little boy eats apple

句型

# 语言的形式化定义

》由文法G的开始符号S推导出的所有句子构成的集合称为文法G生成的语言,记为L(G)。即

$$\circ$$
  $_{\circ}L(G)=\{w/S\Rightarrow^*w,w\in V_T^*\}$  文法  $E\to E+E\mid E*E\mid (E)\mid i$ d 生成的语言中包含多少个句子?

# 例

### ▶文法G

- $2 T \rightarrow L \mid D \mid TL \mid TD$
- (4)  $D \rightarrow 0 \mid 1 \mid 2 \mid 3 \mid ... \mid 9$

该文法生成的语言是:标识符

 $T \Rightarrow TL$ 

 $\Rightarrow TDL$ 

 $\Rightarrow TDDL$ 

 $\Rightarrow TLDDL$ 

• •

作业

 $\Rightarrow TD...LDDL$ 

 $\Rightarrow DD...LDDL$ 


请写出无符号整数 和浮点数的文法

T: 字母数字串

# 语言上的运算

运算	定义和表示
L和M的并	$LUM = \{s \mid s$ 属于L或者s属于M}
L和M的连接	$LM = \{ st \mid s $ 属于 $L$ 且 $t$ 属于 $M \}$
L的幂	$ \begin{cases} L^0 = \{ \varepsilon \} \\ L^n = L^{n-1}L, n \geqslant 1 \end{cases} $
L的Kleene闭包	$L^* = \bigcup_{i=0}^{\infty} L^i$
L的正闭包	$L^{\scriptscriptstyle +} = \cup_{i=1}^{\infty} L^i$

例:  $\diamondsuit L = \{A, B, \dots, Z, a, b, \dots, z\}, D = \{0, 1, \dots, 9\}$ 。则 $L(L \cup D)^*$ 表示的语言是标识符



# 提纲

- 2.1 基本概念
- 2.2 文法的定义
- 2.3 语言的定义
- 2.4 文法的分类
- 2.5 CFG的语法分析树
- 2.6 非上下文无关的语言构造

# Chomsky 文法分类体系

- ▶0型文法 (Type-0 Grammar)
- ▶1型文法 (Type-1 Grammar)
- ▶2型文法 (Type-2 Grammar)
- ▶3型文法 (Type-3 Grammar)

# 0型文法 (Type-0 Grammar)

$$\alpha \rightarrow \beta$$

- ► 无限制文法(Unrestricted Grammar)/短语结构文法 (Phrase Structure Grammar, PSG)
  - $\triangleright \forall \alpha \rightarrow \beta \in P$ ,  $\alpha$ 中至少包含1个非终结符
- ▶ 0型语言
  - $\rightarrow$  由0型文法G生成的语言L(G)

# 1型文法 (Type-1 Grammar)

$$\alpha \rightarrow \beta$$

- ▶ 上下文有关文法(Context-Sensitive Grammar, CSG)
  - $\triangleright \forall \alpha \rightarrow \beta \in P$ ,  $|\alpha| \leq |\beta|$
  - $\triangleright$ 产生式的一般形式:  $\alpha_1 A \alpha_2 \rightarrow \alpha_1 \beta \alpha_2 (\beta \neq \epsilon)$
- ▶ 上下文有关语言 (1型语言)
  - $\triangleright$ 由上下文有关文法 (1型文法) G生成的语言L(G)

CSG中不包含ε-产生式

### 2型文法 (Type-2 Grammar)

$$\alpha \rightarrow \beta$$

- ▶ 上下文无关文法 (Context-Free Grammar, CFG)
  - $\triangleright \forall \alpha \rightarrow \beta \in P, \ \alpha \in V_N$
  - $\triangleright$ 产生式的一般形式:  $A \rightarrow \beta$

# 例: $S \rightarrow L \mid LT$ $T \rightarrow L \mid D \mid TL \mid TD$ $L \rightarrow a \mid b \mid c \mid d \mid ... \mid z$ $D \rightarrow 0 \mid 1 \mid 2 \mid 3 \mid ... \mid 9$

### 2型文法 (Type-2 Grammar)

$$\alpha \rightarrow \beta$$

- ▶ 上下文无关文法 (Context-Free Grammar, CFG)
  - $\triangleright \forall \alpha \rightarrow \beta \in P, \ \alpha \in V_N$
  - $\triangleright$ 产生式的一般形式:  $A \rightarrow \beta$
- ▶ 上下文无关语言 (2型语言)
  - $\triangleright$ 由上下文无关文法 (2型文法) G生成的语言L(G)

# 3型文法 (Type-3 Grammar)

$$\alpha \rightarrow \beta$$

- ▶ 正则文法 (Regular Grammar, RG)
  - 左线性(Right Linear)文法: A→wB 或A→w
  - ► 左线性(Left Linear) 文法: A→Bw 或 A→w
  - 户左线性文法和右线性文法都称为正则文法

#### 例(右线性文法)

- ①  $S \rightarrow a \mid b \mid c \mid d$
- ②  $S \rightarrow aT/bT/cT/dT$
- ③  $T \rightarrow a \mid b \mid c \mid d/0 \mid 1 \mid 2 \mid 3 \mid 4 \mid 5$
- $\textcircled{4} \quad T \rightarrow aT/bT/cT/dT/0T/1T/2T/3T/4T/5T$

### 文法G(上下文无关文法)

- ①  $S \rightarrow L \mid LT$
- $\textcircled{3} L \rightarrow a \mid b \mid c \mid d$

# 3型文法 (Type-3 Grammar)

 $\alpha \rightarrow \beta$ 


- ▶ 正则文法 (Regular Grammar, RG)

  - $\triangleright$  左线性(Left Linear) 文法:  $A \rightarrow Bw$  或  $A \rightarrow w$
  - 产左线性文法和右线性文法都称为正则文法
- ▶ 正则语言 (3型语言)
  - $\triangleright$ 由正则文法(3型文法)G生成的语言L(G)

正则文法能描述程序设计语言的多数单词

# 四种文法之间的关系

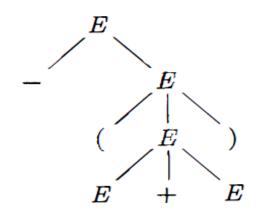
- >逐级限制
  - > 0型文法: α中至少包含1个非终结符
  - ▶1型文法 (CSG) : |α|≤|β|
  - $\triangleright$  2型文法 (CFG) :  $\alpha \in V_N$
  - $\triangleright$  3型文法  $(RG): A \rightarrow wB$  或  $A \rightarrow w \quad (A \rightarrow Bw \text{ id}A \rightarrow w)$
- >逐级包含



### CFG 的分析树

G:

- $(1) E \rightarrow E + E$
- $(2) E \rightarrow E * E$
- $\mathfrak{S} E \rightarrow -E$
- $\textcircled{4}E \rightarrow (E)$
- (5)  $E \rightarrow id$

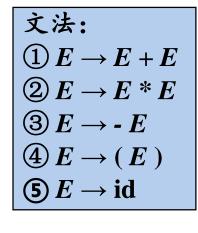


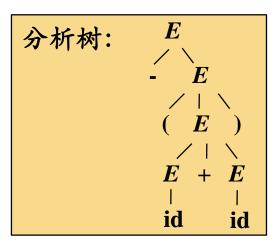
- > 根节点的标号为文法开始符号
- $\triangleright$  内部结点表示对一个产生式 $A \rightarrow \beta$ 的应用,该结点的标号是此产生式 $\Delta \rightarrow \beta$ 的应用,该结点的标号是此产生式 $\Delta \rightarrow \beta$ 的应用,该结点的标号是此产生式 $\Delta \rightarrow \beta$
- ▶ 叶结点的标号既可以是非终结符,也可以是终结符。从左到右排列叶 节点得到的符号串称为是这棵树的产出(yield)或边缘(frontier)

# 分析树是推导的图形化表示

ho 给定一个推导  $S \Rightarrow \alpha_1 \Rightarrow \alpha_2 \Rightarrow ... \Rightarrow \alpha_n$  ,对于推导过程中得到的每一个句型  $\alpha_i$  ,都可以构造出一个边缘为 $\alpha_i$ 的分析树

推导过程:  $E \Rightarrow -E \Rightarrow -(E) \Rightarrow -(E+E) \Rightarrow -(id+E) \Rightarrow -(id+id)$ 





# (句型的)短语

- 〉给定一个句型,其分析树中的每一棵子树的边缘称为该句型的一个短语(phrase)
  - 少如果子树只有父子两代结点,那么这棵子树的边缘称为该句型的一个直接短语(immediate phrase)

#### 文法:

- $\textcircled{1} E \to E + E$
- $\bigcirc E \rightarrow E * E$
- $\textcircled{3} E \rightarrow -E$
- $\textcircled{4}E \rightarrow (E)$
- $(5) E \rightarrow id$

#### 分析树:

E E E E E E E

#### 短语:

- $\rightarrow$  (E+E)
- $\triangleright$  (E+E)
- $\succ E+E$

#### 直接短语:

 $\triangleright E + E$ 

直接短语一定是某产生式的右部

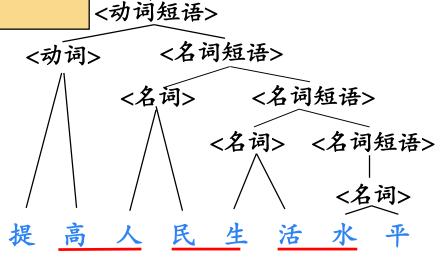
但产生式的右部不一定是给定句型的直接短语

# 例

#### 文法:

- ①<句子>→<动词短语>
- ②<动词短语>→<动词><名词短语>
- ③<名词短语>→<名词><名词短语>|<名词>
- ④<动词>→提高
- ⑤<名词>→ 高 人 | 人 民 | 民 生 | 生 活 | 活 水 | 水 平

输入:提高人民生活水平



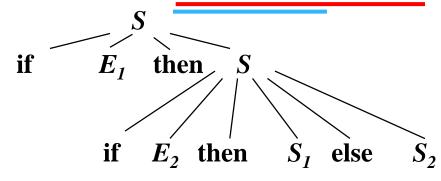
<句子>

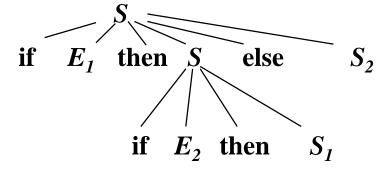
# 二义性文法 (Ambiguous Grammar)

▶如果一个文法可以为某个句子生成多棵分析树,则称这个文法是二义性的

# 例

- 户文法
  - → S→ if E then S | 条件语句 | if E then S else S | 条件语句 | other ← 其他语句
- 户句型
  - $\triangleright$  if  $E_1$  then if  $E_2$  then  $S_1$  else  $S_2$





# 例

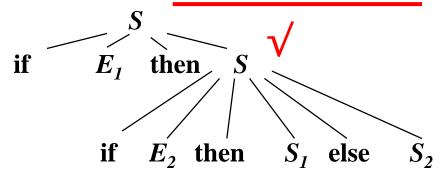
户文法

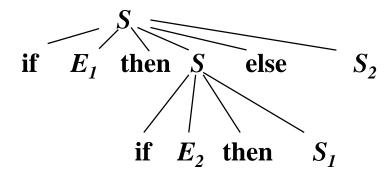
 $\gt S \rightarrow \text{ if } E \text{ then } S$  | if E then S else S | other

消歧规则:每个else和最近的尚未匹配的if匹配

### 户句型

 $\triangleright$  if  $E_1$  then if  $E_2$  then  $S_1$  else  $S_2$ 





# 二义性文法的判定

- ▶对于任意一个上下文无关文法,不存在一个算法, 判定它是无二义性的;但能给出一组充分条件, 满足这组充分条件的文法是无二义性的
  - >满足, 肯定无二义性
  - >不满足,也未必就是有二义性的